Emisión de SOAT 2025: cómo se construyó el análisis

Reserva a diciembre de 2025: 1,77 GB, 3,3 millones de registros, 27 sucursales

Parametrización

Lectura	Separador ~, 9 de 71 columnas
Bloque Dask	128 MB por partición
Clúster 1	2 workers, 2 GB cada uno: 53,5 s
Clúster 2	4 workers, 1 GB cada uno: en curso
Anonimización	Sin identificación del asegurado
Llave	Código de sucursal + póliza
Salida	Parquet con fechas y valores tipados

Codificación

```
ddf = dd.read_csv(ruta, sep="~",
    usecols=columnas, dtype=str,
    blocksize="128MB")
dias = ddf.inicio_vigencia - ddf.fecha_emision
ddf["dias_anticipacion"] = dias.dt.days
ddf.to_parquet("reserva_parquet")
```

Variables creadas: mes_emision y dias_anticipacion. Objetivo definido: tuvo_siniestro (1 o 0).

Hecho: anonimización, EDA y cruce con siniestros

En curso: segunda configuración de Dask

Pendiente: Prefect, AWS, Grafana, informe y GitHub

Diciembre concentra la emisión y la reserva

Primeros hallazgos del análisis exploratorio sobre 3,3 millones de pólizas



+57 %

Pólizas de diciembre frente al promedio de enero a noviembre

22 %

De la reserva al cierre (cerca de $610.000 millones) viene de lo emitido en diciembre

1 día

Mediana entre la compra y el inicio de vigencia

Alcance: la base cubre un solo año de emisión, por lo que se describe 2025 y no se afirma estacionalidad. Siniestros enlazados: 53 % de los registros.